

1. 绪论

1.1. 什么是人工智能

1.1.1. 什么是智能==(记下来)==

- 1 思维理论：知识来自于思维，智能的核心是思考和推理能力
- 2 知识阈值理论：智能取决于知识量及其一般化程度
- 3 进化理论：有感知外界，适应环境的能力
- 👉 总结：智能=智力+知识
- 🔥 补充：智能的具体特征——感知外界+记忆思维+学习自适应+行为能力

1.1.2. 智能的特征==(记下来)==

- 1 具有感知能力
- 2 具有记忆和思维能力
- 3 能够学习和自适应
- 4 具有行为能力

1.1.2. 图灵&深蓝

- 1 图灵测试：由能否在对话中欺骗人类，判断机器是否有类智能；侧重知识阈值理论
- 2 图灵的梦想：创造能够模仿人类智能的机器或计算机系统
- 3 深蓝：IBM的超级计算机，首次击败国际象棋世界冠军；侧重思维理论
- 4 图灵的梦想更难实现

1.2. AI发展史及重要事件

- 1 孕育(1956前):
- 2 形成(1956-1969):
 - 1. 1956: 麦卡锡提出人工智能一词
 - 2. 1965: 第一个专家系统诞生
- 3 发展(1970后):
 - 1. 1982: Hopfield网络提出
 - 2. 1986: BP网络提出
 - 3. 1995: SVM提出
 - 4. 2006: 深度学习提出
 - 5. 2016: Alpha Go

1.3. AI研究内容

- 1 机器感知：模式识别
- 2 机器思维：知识表示/推理/搜索，神经网络
- 3 机器学习
- 4 机器行为：人工智能

1.4. 人工智能的应用

- 1 专家系统，知识工程，机器学习，模式识别，NLP，机器定理证明
- 2 博弈论，智能决策，人工神经网络，机器人

2. 知识工程

2.1. 知识

- 1 知识定义：有关信息关联在一起所形成的信息结构
- 2 ==知识特性：相对正确，不确定性(随机/模糊/不完全/经验)，可表示可利用==
- 3 知识分类：常识/领域，事实/规则(因果)，确定/不确定

2.2. 知识的表示

2.2.1. 概述

- 1 什么是知识表示：用计算机可以接收的数据结构，来描述知识
- 2 知识的表示方法：==符号表示(逻辑性知识，有命题逻辑+谓词逻辑)==，神经网络表示

2.2.2. 符号逻辑表示：命题逻辑

- 1 命题：有真假意义的语句，用大写字母表示
- 2 缺陷：无法描述客观事物的结构和逻辑关系；好比只能描述AB的对错，不能描述AB之间的关系

2.2.3. 符号逻辑表示：一阶谓词逻辑

接近自然语言，容易在计算机上实现

- 1 谓词结构：谓词名+个体，如Teacher(Wang)，一般形式为 $P(x_1, x_2, \dots, x_n)$
 1. 个体：可以是变量，常量，函数(谓词)；变量个体必有定义域
 2. 谓词名：含义由人指定；可以说Teacher(wang)是王老师，也可以说是王老师
- 2 谓词有真假，又是需要确定变元才可判断真假
- 3 谓词连接词：非 $\neg$ ，析取 $\vee$ ，合取 $\wedge$ ，蕴含 $\rightarrow$ ，等价 $\Leftrightarrow$

P	Q	$\neg P$	$P \vee Q$	$P \wedge Q$	$P \rightarrow Q$	$P \Leftrightarrow Q$
T	T	F	T	T	T	T
T	F	F	T	F	F	F
F	T	T	T	F	T	F
F	F	T	F	F	T	T

有关蕴含关系

1. 蕴含实质上是一种因果， $P \rightarrow Q$ 中P是前提Q是结论， $P \rightarrow Q$ 为真表示因果关系成立
2. $P \rightarrow Q$ 中P作为前提为F时，则认为 $P \rightarrow Q = T$ ，前提都不成立，姑且就认为你是对的
==只要不是错误前提推出真结论都认为蕴含关系成立==

- 4 谓词公式：按照以下规则得到的合式公式
 1. 单个谓词(原子公式)
 2. 单个合式公式的否定
 3. 两个合式公式的 $\vee$ ， $\wedge$ ， $\rightarrow$ ， $\Leftrightarrow$
 4. 以上规则的有限步骤
- 5 谓词等价式&永真蕴含式(不用刻意记)

等价式(等价号左右同真假)，取几个特殊的：

$$\begin{aligned}(P \vee Q) \vee R &\Leftrightarrow P \vee (Q \vee R) \\ P \vee (Q \wedge R) &\Leftrightarrow (P \vee Q) \wedge (P \vee R) \\ \neg(P \vee Q) &\Leftrightarrow \neg P \wedge \neg Q \\ P \rightarrow Q &\Leftrightarrow \neg P \vee Q \\ P \leftrightarrow Q &\Leftrightarrow (P \rightarrow Q) \wedge (Q \rightarrow P)\end{aligned}$$

永真蕴含式($\Rightarrow$ 表示左边为真右边也为真)，取几个特殊的：

$$\begin{aligned}\neg P, P \vee Q &\Rightarrow Q \text{ (二者同时为真, 则Q为真)} \\ P, P \rightarrow Q &\Rightarrow Q \\ \neg Q, P \rightarrow Q &\Rightarrow \neg P \\ P \rightarrow Q, Q \rightarrow R &\Rightarrow P \rightarrow R \\ (\exists x)P(x) &\Rightarrow P(y) \\ (\forall x)P(x) &\Rightarrow P(a)\end{aligned}$$

- 6 谓词推理规则
 1. P规则：任何推理步可引入前提
 2. T规则：前步骤的公式永真蕴含S，则S可引入为该步前提
 3. CP规则： $R + \text{前提} \Rightarrow S$ ，则前提 $\Rightarrow R \rightarrow S$
 4. 反证法： $P \Rightarrow Q$ ，当且仅当 $P \wedge \neg Q$ 不可满足
- 7 基于谓词的知识表示

1. 先定义谓词指出其特殊含义
2. 用连接词连接谓词：用 $\vee$ $\wedge$ 连接表示事实，有 $\rightarrow$ 连接表示规则

2.2.4. 产生式表示法：模仿人的思考

1 事实的表示


1. 三元组：(A, age, 40)A年龄为40
2. 四元组：用于表示不确定性, (gay, A, B, 0.8)A和B有80%可能是gay

2 规则表示：如果P则Q, $P \rightarrow Q$ (置信度为p)

3 产生式系统：综合数据库(事实库) $\xleftrightarrow{\text{产生式规则库}}$ 产生式规则库

1. 规则库：描述相应领域知识的产生式集合
2. 事实库：已知事实+推导出事实
3. 控制系统：负责规则匹配与执行管理

4 产生式系统求解步骤



5 示例

数据库：{有毛,吃草,黑条纹}

规则库：R1：有毛 $\rightarrow$ 哺乳类

R3：哺乳类 $\wedge$ 吃肉 $\rightarrow$ 食肉类

R4：哺乳类 $\wedge$ 吃草 $\rightarrow$ 有蹄类

R5：食肉类 $\wedge$ 黄褐色 $\wedge$ 有斑点 $\rightarrow$ 猎狗

R6：有蹄类 $\wedge$ 黑条纹 $\rightarrow$ 斑马

1. 匹配到R1 $\rightarrow$ 更新事实库：{哺乳动物,有毛,吃草,黑条纹}
2. 匹配到R4 $\rightarrow$ 更新事实库：{哺乳动物,有毛,吃草,黑条纹,有蹄类}
3. 匹配到R6 $\rightarrow$ 更新事实库：{哺乳动物,有毛,吃草,黑条纹,有蹄类,斑马}

3. 确定性推理

3.1. 概述

3.2.1. 推理机&推理种类

1 推理机：程序实现的推理

2 推理种类：

1. 演绎推理(如几何证明)，归纳推理(个体到一般)，默认推理(假设某个缺省条件成立)
2. 确定性推理(基于确切知识)，不确定性推理(处理含糊信息)
3. 单调推理(推出结论单调增加)，非单调推理(比如缺省推理)

3.2.2. 推理方向

1 正向推理(数据驱动)：

1. 用户已知事实+知识库(KB)中的适用知识 $\rightarrow$ 可用知识集(KS)
2. 从KS选一个知识进行推理，推理结果存入数据库(DB)作为下次推理的已知事实
3. 循环往复

2 逆向推理：选一个假设目标 $\rightarrow$ 寻找支持假设所需证据，能全找到说明假设成立

3.2. 知识匹配&变量代换

0 知识匹配：判断两个知识模式是否一致，有确定(完全匹配)/不确定之分(有置信度)

3.2.1. 变量代换概念

1 概念：

1. 简单的理解：用==变量表示规则==，用==常量换掉后就变成事实==
2. 定义：有限集 $\theta = \{t_1/x_1, \dots, t_n/x_n\}$ 中 t_i 为常量(也可能为变量或函数)， x_i 为互不相同的变元， $/$ 表示左边换掉右边的
3. 特例：用一组代换去换掉表达式中的变量，例如 $F\theta$ 表示用 θ 替换去替换 F 中的变量

2 代换规则：

1. $t_i \neq x_i$ ，两个相同还替换啥
2. $\forall t_j$ 中不含 $\forall x_i$ ，例如 $g(y)/\mathbf{f}(x), \mathbf{f}(\mathbf{f}(x))/y$ 就不是代换

3.2.2. 代换的复合

1 如何得到代换复合：对于 $\theta = \{t_1/x_1, \dots, t_n/x_n\}$ 和 $\lambda = \{u_1/y_1, \dots, u_m/y_m\}$

1. 令 $\theta \circ \lambda = \{t_1 \circ \lambda / x_1, \dots, t_n \circ \lambda / x_n\}$ ，然后合并为 $(\theta \circ \lambda)_{\text{RAW}} = \{\theta \circ \lambda, \lambda\}$
2. 删除 $\theta \circ \lambda$ 中满足 $t_i \circ \lambda = x_i$ 的项，删除 λ 中满足 $y_i \in \{x_1, \dots, x_n\}$ 的
3. 完成上述操作后 $(\theta \circ \lambda)_{\text{RAW}} \rightarrow$ 形成复合 $\theta \circ \lambda$

2 复合的性质： $F(\theta \circ \lambda) = (F\theta) \circ \lambda$

3 复合的示例： $\theta = \{f(y)/x, z/y\}$ ， $\lambda = \{a/x, b/y, y/z\}$

1. $\theta \circ \lambda = \{f(y)/x, z/y, a/x, b/y, y/z\}$
2. $= f(y)/x$ 表示在 $f(y)$ 中运用 λ 替换得到 $f(b)$ ， z/y 表示在 z 中运用 λ 替换得到 y
3. 化简为 $\{f(b)/x, y/y, a/x, b/y, y/z\} = \{f(b)/x, y/z\}$


3.2.3. 公式的合一(特殊的代换)

1 定义：公式集 $F = \{F_1, \dots, F_n\}$ 存在代换 θ 使 $F_1\theta = F_2\theta = \dots = F_n\theta$ ，则


1. θ 为公式 F 的一个合一，公式合一==一般不唯一==
2. 公式集 $F = \{F_1, \dots, F_n\}$ 可合一

2 最一般合一(唯一)： σ 为公式集 F 最一般合一 $\iff$ 其它合一都可表示为 $\sigma \circ \theta_i$ (θ_i 为相应代换)

3 最一般合一求法：发现差异，消除差异



4 示例



3.3. 归结演绎推理

🌱 定理证明：证明 $P \rightarrow Q$ (等价于 $\neg P \vee Q$) 的永真，或者 $P \wedge \neg Q$ 永假


3.3.1. 海伯论理论

1 文字，子句，子句合取范式，子句集


1. 文字：==原子谓词公式==及其否定，如 $\neg P(x, f(x))$, $Q(x, g(x))$
2. 子句：任何==文字的析取==，如 $C = P(x, f(x)) \vee Q(x, g(x))$ ，不包含任何文字的子句为空子句
3. 子句合取范式： $C_1 \wedge C_2 \wedge \dots \wedge C_n$
4. 子句集： $S = \{C_1, C_2, \dots, C_n\}$ ，仍和谓词公式都可化成子句集，途径是**等价和推理**

2 谓词公式化为子句集：==以 $\neg(\forall x)[(\forall y)P(x, y) \rightarrow \neg(\forall y)(Q(x, y) \rightarrow R(x, y))]$ 为例==

1. 消去 $\rightarrow$ 和 $\leftrightarrow$ (用等价关系)



2. 让 $\neg$ 紧靠谓词(用等价关系)



3. 重命名变元，使不同量词约束的变元名字不同

$$(\forall x) [(\exists y) \neg P(x, y) \vee (\exists y) (Q(x, y) \wedge \neg R(x, y))]$$

两个量词约束变量都为y
故修改一个y为z

$$(\exists z) (Q(x, z) \wedge \neg R(x, z))$$

合为: $(\forall x) [(\exists y) \neg P(x, y) \vee (\exists z) (Q(x, z) \wedge \neg R(x, z))]$

4. 消去存在量词

① $\exists$ 不在 $\forall$ 辖域内, 则用一新个体常量 $\xrightarrow{\text{Replace}}$ 受该 $\exists$ 约束的变元
此处不适用.

② $\exists$ 在 $\forall$ 辖域内, 用 Skolem 函数 $f(x_1, x_2, \dots, x_n)$
此处适用

$$(\forall x) [(\exists y) \neg P(x, y) \vee (\exists z) (Q(x, z) \wedge \neg R(x, z))]$$

- $\exists y$ 与 $\exists z$ 在 $\forall x$ 辖域内.
- 设 y, z 的 Skolem 函数为 $f(x), g(x)$
- 替换后: $(\forall x) [\neg P(x, f(x)) \vee (Q(x, g(x)) \wedge \neg R(x, g(x)))]$

5. 全称量词移到公式左边, 示例中 $\forall$ 已经在左边

6. 将公式化为 Skolem 标准形(用等价关系)

Skolem 标准形 $(\forall x_1)(\forall x_2) \dots (\forall x_n) M$
其中 M 为合取式; 称为 Skolem 标准形公式.

$$(\forall x) [\neg P(x, f(x)) \vee (Q(x, g(x)) \wedge \neg R(x, g(x)))]$$

$$(\forall x) \{ [\neg P(x, f(x)) \vee Q(x, g(x))] \wedge [\neg P(x, f(x)) \vee \neg R(x, g(x))] \}$$

7. 消去全称量词, 消去合取词, 就得到了子句集

$$(\forall x) \{ [\neg P(x, f(x)) \vee Q(x, g(x))] \wedge [\neg P(x, f(x)) \vee \neg R(x, g(x))] \}$$

① 消去 $\forall$, 直接删去 $\forall x$ 即可.

$$[\neg P(x, f(x)) \vee Q(x, g(x))] \wedge [\neg P(x, f(x)) \vee \neg R(x, g(x))]$$

② 取消 $\wedge$, 即得到子句集

$$\{ [\neg P(x, f(x)) \vee Q(x, g(x))], [\neg P(x, f(x)) \vee \neg R(x, g(x))] \}$$

3 子句集的意义

- 不可满足性: $S = \{S_1, S_2, \dots, S_n\}$ 中, 任何论域的任何解释, 都不可能让所有 S_i 都为真 ==
- 定理: 谓词公式 F 不可满足 $\iff$ 其子句集 S 不可满足
- $\models P \iff \neg P \iff P \vee Q$ 永真 $\iff P \wedge \neg Q$ 永假 $\iff P \wedge \neg Q$ 的子句集 S 不可满足 ==

4 Herbrand 理论

- 判断子句集不可满足, 需要对所有可能论域上的所有解释进行判定

2. Herbrand理论中, 构造了Herbrand域, 代替以上一句话中的所有域

3.3.2. 鲁宾逊归结原理

原理概述: 子句集 S 中有空子句必不可满足, S 中的子句进行归结后能得到空子句则也不可满足

3.3.2.1. 命题逻辑中的归结原理

1 互补文字: 也就是 P 和 $\neg(P)$, P 可为谓词公式或命题

2 归结操作: 归结式&亲本子句

- C_1, C_2 是子句集中的任意两个子句, L_i 是 C_i 的文字
- 如果 L_1, L_2 互补, 则分别在 C_1, C_2 中删除二者
- 将现有 C_1, C_2 余下部分析取, 得到 C_{12}
- C_{12} 是 C_1, C_2 的归结式, C_1, C_2 是 C_{12} 的亲本子句

例如 $C_1 = \neg(P \vee Q), C_2 = \neg(Q) \vee R \text{ iff } C_{12} = \neg(P) \vee R$

3 定理: C_1, C_2 是子句集 S 中的子句, 则归结式 C_{12} 是 C_1, C_2 的逻辑结论, 即 $C_1 \wedge C_2 \rightarrow C_{12}$

- 推论1: $S \rightarrow (C_{12} \text{ 代替 } C_1, C_2) S_1$, 则 S_1 不可满足性 $\rightarrow S$ 不可满足性
- 推论2: $S \rightarrow (C_{12} \text{ 加入 } S) S_2$, 则 S_2 不可满足性 $\text{iff } S$ 不可满足性

+ 证明子句集 S 不可满足:

- 对句集进行归结子
- 把归结式进行加入/替换, 得到 S_2 或 S_1
- 证明二者之一不可满足, 即可证明 S 不可满足(若是空集则 S 直接不可满足)

4 命题逻辑归结原理的完备性: 子句集不可满足 iff 必有一个从 S 到空子句的归结演绎

3.3.2.2. 谓词逻辑的归结原理

1 规则: 不能直接消去两个子句中互补的文字, 需要用最一般合一 θ 对变元代换, 再归结

2 示例


$$\begin{aligned} C_1 &= P(x) \vee Q(x), C_2 = \neg P(a) \vee R(y) \\ \text{最一般合一 } \theta &= \{a/x\} \\ C_1\theta &= P(a) \vee Q(a), C_2\theta = \neg P(a) \vee R(y) \\ \Rightarrow \text{归结为 } C_{12} &= Q(a) \vee R(y) \end{aligned}$$

3.3.3. 归结反演: 证明 Q 为 $P_1, P_2, \dots, P_n$ 逻辑结论

1 以下命题等价

- Q 是 $P_1, P_2, \dots, P_n$ 的逻辑结论, 即 $(P_1, P_2, \dots, P_n) \rightarrow Q$
- $\neg(P_1 \wedge P_2 \wedge \dots \wedge P_n) \vee Q$ 永真
- $(P_1 \wedge P_2 \wedge \dots \wedge P_n) \wedge \neg Q$ 不可满足
- $(P_1 \wedge P_2 \wedge \dots \wedge P_n) \wedge \neg Q$ 的子句集不可满足

2 归结反演步骤: $F = \{P_1, P_2, \dots, P_n\}$ 为已知前提公式集, Q 为目标公式(结论)



+ 示例

$F: (\forall x) [(\exists y) (A(x,y) \wedge B(y)) \rightarrow (\exists y) (C(y) \wedge D(x,y))]$
 $G: \neg(\exists x) C(x) \rightarrow (\forall x) (\forall y) [A(x,y) \rightarrow \neg B(y)]$
 证明 $G \rightarrow F$, 即 $\neg G \vee F$ 永真.

取变元集 $\{ F = \{ \neg A(x,y) \vee \neg B(y) \vee C[f(x)], \neg A(x,y) \vee \neg B(y) \vee D[x, f(x)] \}$
 $G = \{ \neg C(z), A(a,b), B(b) \}$

方法: $\neg A(x,y) \vee \neg B(y) \vee C[f(x)]$ $\neg C(z)$ $\rightarrow$ 最一般合 - $\{f(x)/z\}$
 $\neg A(x,y) \vee \neg B(y)$ $A(a,b)$ $\rightarrow$ 最一般合 - $\{a/x, b/y\}$
 $\neg B(y)$ $B(b)$ $\rightarrow$ 最一般合 - $\{b/y\}$
 空子句 $\Rightarrow$ 证毕, $G \rightarrow F$ 成立.

3.3.4. 归结策略(看懂这个例子)

1 归结的一般过程

1. $S = \{C_1, C_2, \dots, C_n\}$ 中任意两两归结, 得到第一级归结式 S_1
2. 把 S, S_1 任意子句两两归结, 得到二级归结式 S_2
3. 把 S, S_1, S_2 任意子句两两归结, 得到三级归结式 S_3
4. 循环, 直到出现空子句/不能继续归结, 示例如下

① 第一次归结

$S = \{P, \neg R, \neg P \vee Q, \neg Q \vee R\}$
 $S_1 = \{Q, \neg Q, \neg P \vee R\}$

② 第二次归结

$\{S, S_1\} = \{P, \neg R, \neg P \vee Q, \neg Q \vee R, Q, \neg Q, \neg P \vee R\}$
 $S_2 = \{R, \neg P, \neg P, R\}$

③ 第三次归结

$\{S, S_1, S_2\} = \{P, \neg R, \neg P \vee Q, \neg Q \vee R, Q, \neg Q, \neg P \vee R, R, \neg P, \neg P, R\}$
 $S_3 = \{\text{NIL}\}$ 归结完成

2 删除策略: 删除无用子句来缩小归结范围

1. 纯文字:

- 文字 L 在子句集中但 $\neg L$ 不在, 那么 L 就是纯文字
- 如 $\{P, \neg R, \neg(P \vee Q), Q \vee W\}$ 的 W
- 纯文字所在子句删掉

2. 重言式:

- 子句包含互补文字时, 该子句就为重言式子句
- 如 $P \vee \neg(P \vee Q)$
- 重言式子句删掉


3. 包孕式:

- σ_1 代换 σ_2 ($\sigma_1 \subseteq \sigma_2$), 则 C_1 包孕于 C_2 (C_2 包孕了 C_1)
- 如 $C_1 = P(x), C_2 = P(y) \vee Q(z)$
- C_1 包孕于 C_2 时删除 C_2


3 支持集的限制策略:

1. 支持集: 目标公式的否定得到的子句 + 其后裔(其与别的子句归结的结果)

2. 支持集策略：每次归结，亲本子句中必须有一方属于支持集
3. 支持集策略完备



4. 线性输入的限制策略：归结的两个子句中，必须至少有一个是初始子句集中的子句




5. 线性输入策略 $\rightarrow$ (放宽) 祖先过滤策略：要求 $C_1 C_2$ 归结时

1. 二者至少之一是初始子句集中的子句
2. 二者中一个是另外一个的祖先

3.3.5. 用归结原理求取问题(这里的例子可以不用看)


1 步骤概览




2. 示例：A,B,C 三人， $T(x)$ 表示 x 说真话，证明 $\neg T(A)$

1. 有人全说谎，有人全说真
2. A说：BC说谎
3. B说：AC说谎
4. C说：AB至少一人说谎

前提化为子句集




整理, 简化子句集



开始归结



推广: 题目改为, 判断谁是说真话, 引入 Answer 谓词



4. 不确定性推理

4.1. 概念


1 不确定性推理: 不确定事实(证据) $\rightarrow$ {不确定的规则(知识)} $\rightarrow$ 不确定结论

1. 知识静态强度: 知识不确定性, 用数值表示, 由专家系统给出(所以静态)
2. 知识动态强度: 证据不确定性, 用数值表示

2 不确定性匹配算法

1. 匹配度: 证据和知识的前提(已知事实)的相似程度
2. 匹配算法: 求这个匹配度

3 不确定性推理方法的分类



4.2. 基本概率方法

1 经典概率方法：if 前提E then 结论H

- 大量统计可得\$E\$发生后\$H\$发生的概率，记为 $P(H|E)$ (后验概率)
- $P(H|E)$ 就是证据\$E\$下结论\$H\$的可信度

2 逆概率方法：前提\$E\$对应有很多结论\$H_1, H_2, \dots, H_n\$

```

if 前提E then 结论H1, H2, ..., Hn
=>
if 前提E then 结论H1
if 前提E then 结论H2
.....
if 前提E then 结论Hi
.....
if 前提E then 结论Hn
  
```

$P(H_i | E) = \frac{P(H_i) \times P(E | H_i)}{\sum_{j=1}^n P(H_j) \times P(E | H_j)}$, $\square i = 1, 2, \dots, n$ (这个公式不用记)

4.3. 主观Bayes方法

4.3.1. 不确定性的表示

1 知识的不确定性：IF E THEN (LS, LN) H(P(H))

- $P(H)$: 结论\$H\$的先验概率，由专家根据经验给出
- ==静态强度== LS, LN : 由专家给出，==这两个表达式不用记==
 - $LS = \frac{P(E|H)}{P(E|\neg H)} \in [0, \infty)$: 充分性度量，指出\$E\$对\$H\$的支持程度
 - $LN = \frac{P(\neg E|H)}{P(\neg E|\neg H)} = \frac{1 - P(E|H)}{1 - P(E|\neg H)} \in [0, \infty)$: 必要性度量，指出 $\neg E$ 对\$H\$的支持程度

2 证据的不确定性

- ==动态强度== $P(E|S)$: 对于证据\$E\$，由用户根据观测\$S\$，给出 $P(E|S)$
- 可信度 $C(E|S)$: 用来代替 $P(E|S)$ ，其在PROSPECTOR(矿勘专家系统)中

$$P(E|S) = \begin{cases} \frac{C(E|S) + P(E) \times (5 - C(E|S))}{5}, & 0 \leq C(E|S) \leq 5 \\ \frac{P(E) \times (5 + C(E|S))}{5}, & -5 < C(E|S) < 0 \end{cases}$$

$C(E S) \in \{-5, \dots, 5\}$	含义
-5	观测\$S\$下证据\$E\$不存在，即 $P(E S)=0$
5	观测\$S\$下证据\$E\$存在， $P(E S)=1$
0	\$S, E\$之间无关， $P(E S)=P(E)$

3 结论的不确定性：二者关系间==4.3.2.2. 3 ==

- 后验概率 $P(H|E)$: 给出证据\$E\$情况下结论\$H\$为真的概率
- 结论可信度 $P(H|S)$: 考虑了观察\$S\$后结论\$H\$为真的概率

3 组合证据的不确定性

1. 二维组合

	最大最小法	概率法	有界法
$T(E_1 \wedge E_2)$	$\min\{T(E_1), T(E_2)\}$	$T(E_1) * T(E_2)$	$\max\{0, T(E_1) + T(E_2) - 1\}$
$T(E_1 \vee E_2)$	$\max\{T(E_1), T(E_2)\}$	$T(E_1) + T(E_2) - T(E_1) * T(E_2)$	$\min\{1, T(E_1) + T(E_2)\}$

2. 多维组合

$$P(E_1 \wedge E_2 \wedge \dots \wedge E_n | S) = \min\{P(E_1 | S), P(E_2 | S), \dots, P(E_n | S)\}$$

$$P(E_1 \vee E_2 \vee \dots \vee E_n | S) = \max\{P(E_1 | S), P(E_2 | S), \dots, P(E_n | S)\}$$

$$P(\neg E | S) = 1 - P(E | S)$$

4.3.2. 不确定的传递

4.3.2.1. 前置概念

- 1 什么是不确定的传递：证据不确定性+知识不确定性 $\xrightarrow{\text{用遗传算法算出算出}}$ 结论的不确定性
- 2 $\Theta(x) = \frac{P(x)}{1-P(x)}$ $\in [0, 1] \rightarrow [0, \infty]$, $\Theta(x)P(x)$ 单调性相同

4.3.2.2. 三种情况(推导详见课本P92)——计算题重灾区——

- 1 证据一定存在 $P(E) = P(E|S) = 1$ (不论观测与否，证据都成立)
 - $P(H|E) = \frac{LS \times P(H)}{(LS - 1) \times P(H) + 1}$
 - 或者 $\Theta(H|E) = LS \times \Theta(H)$
- 2 证据一不存在 $P(E) = P(E|S) = 0$ (不论观测与否，证据都不成立)
 - $P(H|\neg E) = \frac{LN \times P(H)}{(LN - 1) \times P(H) + 1}$
 - 或者 $\Theta(H|\neg E) = LN \times \Theta(H)$
- 3 证据可能存在 $0 < P(E|S) < 1$ 时： $P(H|S) = P(H|E) \times P(E|S) + P(H|\neg E) \times P(\neg E|S)$

1. $P(E|S) = 1$ 时， $P(H|S) = P(H|E)$
观察后一定能获得证据，所以基于观察的可信度和基于证据的可信度就都一样了
2. $P(E|S) = 0$ 时， $P(H|S) = P(H|\neg E)$
观察后一定不能获得证据，所以基于观察的可信度等于基于无证据的可信度
3. $P(E|S) = P(E)$ 时， $P(H|S) = P(H)$
不论观察与否，证据的可信度都不变，所以不论观察与否结论的可信度也不会变
4. 其余情况：

$$P(H|S) = \begin{cases} P(H|\neg E) + \frac{P(H) - P(H|E)}{P(E)} \times P(E|S), & 0 \leq P(E|S) < P(E) \\ P(H) + \frac{P(H|E) - P(H)}{1 - P(E)} \times [P(E|S) - P(E)], & P(E) \leq P(E|S) \leq 1 \end{cases}$$

- 这是 EH 公式， $C(E/S)$ 换掉 $P(E/S)$ 便是 CP 公式
- 这个公式不用记，只需要知道这是分段差值法求来的

4.3.2.3. LS和LN 的性质

- 1 $LS > 1$ 说明证据 E 对结论 H 有利， $LN > 1$ 说明证据 $\neg E$ 对结论 H 有利
- 2 记住：一般情况取 $LS > 1, LN < 1$

4.3.3. 结论不确定性的合成

- 1 概念： $A_1, A_2, \dots, A_n \rightarrow$ {合成算法} A 的不确定性到底是多少

```
if 前提E1 then (LS1, LN1) 结论H(p(H)) ----> 对应观察S1
if 前提E2 then (LS2, LN2) 结论H(p(H)) ----> 对应观察S2
.....
if 前提En then (LSn, LNn) 结论H(p(H)) ----> 对应观察Sn
```

- 2 $\Theta(H|S_1, S_2, \dots, S_n) = \frac{\Theta(H|S_1)}{\Theta(H)} \times \frac{\Theta(H|S_2)}{\Theta(H)} \times \dots \times \frac{\Theta(H|S_n)}{\Theta(H)} \times \Theta(H)$

4.4. 可信度模型

4.4.1. 阈值可信度模型——(计算题重灾区)——

- 1 表示不确定性：IF E THEN H(CF(H, E), λ)
 1. $CF(E) \in [0, 1]$ ：证据 E 的可信度， $CF(E) = 1/0$ 表示证据绝对存在/不存在
 2. $CF(H, E) \in [0, 1]$ ：证据 E 为真时 H 的可信度， $CF(H, E) = 0, 1$ 对应 $P(H|E) = 0, 1$
 3. $\lambda \in [0, 1]$ ：阈值，只有证据 E 可信度 $CF(E) \geq \lambda$ 时知识 E 才能被应用

- 2 组合证据的不确定性

$CF(E_1 \text{ and } E_2 \text{ and } \dots \text{ and } E_n) = \min\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$

$CF(E_1 \text{ or } E_2 \text{ or } \dots \text{ or } E_n) = \max\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$

- 3 不确定性的传递算法： $CF(E) \geq \lambda$ 时 $CF(H) = CF(H, E) \times CF(E)$

- 4 结论不确定性合成算法：IF E_i THEN H(CF(H, E_i), λ_i) $i = 1, 2, \dots, n$

- 前提: $\forall i \in \{1, 2, \dots, n\}, \lambda \leq CF(E_i)$
- 结论 H 的可信度:

方法	$CF(H)$ 等于
极大值法	$\max\{CF_i(H)\}, i=1, 2, \dots, n$
加权法和	$\frac{\sum_{i=1}^n CF(H, E_i) \times CF(E_i)}{\sum_{i=1}^n CF(H, E_i)}$
有限和法	$\min\{\sum_{i=1}^n CF_i(H), 1\}$
递推法	$C_0=0, C_k = C_{k-1} + (1 - C_{k-1}) \times CF(H, E_k) \times CF(E_k)$

4.4.2. 加权可信度模型==(计算题重灾区)==

1 知识的不确定性:

- 表示: $IF E_1(w_1) AND E_2(w_2) AND \dots AND E_n(w_n) THEN H(CF(H, E), \lambda)$
- 阈值 λ : 由专家给出
- 加权因子 ω_i : 由专家给出, 满足 $\sum_{i=1}^n \omega_i = 1$

2 组合证据的不确定性: $CF(E) = \frac{\sum_{i=1}^n \omega_i CF(E_i)}{\sum_{i=1}^n \omega_i}$

3 不确定性传递算法: 当 $CF(E) \geq \lambda$ 时 $CF(H) = CF(H, E) \times CF(E)$

4.4.3. 前件带不确定性的可信度模型==(计算题重灾区)==

1 表示:

- 表示1: CF_i 是子条件 E_i 的可信度由专家给出, 子证据 E_i 的可信度 CF_i

$IF E_1(CF_1) AND E_2(CF_2) AND \dots AND E_n(CF_n) THEN H(CF(H, E), \lambda)$

- 表示2: 加上权值

$IF E_1(CF_1, w_1) AND E_2(CF_2, w_2) AND \dots AND E_n(CF_n, w_n) THEN H(CF(H, E), \lambda)$

3 不确定性匹配

- 无加权因子: $\sum_{i=1}^n \max(0, CF_i - CF_{f_i}) \leq \lambda$
- 有加权因子: $\sum_{i=1}^n \omega_i \max(0, CF_i - CF_{f_i}) \leq \lambda$

4 不确定性的传递算法

- 无加权因子: $CF(H) = \left[\prod_{i=1}^n (1 - \max(0, CF_i - CF_{f_i})) \right] \times CF(H, E)$
- 有加权因子: $CF(H) = \left[\prod_{i=1}^n (1 - \omega_i \max(0, CF_i - CF_{f_i})) \right] \times CF(H, E)$

4.5. 模糊推理

4.5.1. 模糊理论模糊集

4.5.1.1. 模糊集

1 $\mu_A: U \rightarrow [0, 1]$, 将任意 $u \in U$ 映射到 $[0, 1]$ 上的某个函数

- 模糊集: $A = \{\mu_A(u), u \in U\}$ 称为 U 上的一个模糊集,
- μ_A : 定义在 U 上的模糊集 A 的隶属函数
- $\mu_A(u)$: u 对模糊集 A 的隶属度

2 离散论域 U 的模糊集 A , 以下表示中应剔除 $\mu_A(u_i) = 0$ 的

- 表示1: $A = \{\mu_A(u_1), \mu_A(u_2), \dots, \mu_A(u_n)\}$
- 表示2: $A = \mu_A(u_1)/u_1 + \mu_A(u_2)/u_2 + \dots + \mu_A(u_n)/u_n = \sum_{i=1}^n \{\mu_A(u_i)/u_i\}$
- 表示3: $A = \{\mu_A(u_1)/u_1, \mu_A(u_2)/u_2, \dots, \mu_A(u_n)/u_n\} = \bigcup_{i=1}^n \{\mu_A(u_i)/u_i\}$
- 表示4: $A = \{[\mu_A(u_1), u_1], [\mu_A(u_2), u_2], \dots, [\mu_A(u_n), u_n]\}$

3 连续论域 U 的模糊集 $A = \int \limits_{u \in U} \{\mu_A(u)/u\}$

4 U 上所有模糊集表示为: $\mathcal{F}(U) = \{A \mid \mu_A: U \rightarrow [0, 1] \text{ 或 } F(U) = \{\mu_A \mid \mu_A: U \rightarrow [0, 1]\}$

4.5.1.2. 模糊集的运算

1 B 包含于 A : $A, B \in \mathcal{F}(U), \forall u \in U, \mu_B(u) \leq \mu_A(u) \rightarrow B \subseteq A$

2 A, B 的交并补: ==

- $A \cup B: \mu_{A \cup B}(u) = \max\{\mu_A(u), \mu_B(u)\} = \mu_A(u) \vee \mu_B(u)$

- 例如 $\mu_A(1)=0.3/1, \mu_B(u)=0.4/1$ 则 $\mu_{A \cup B}(1)=\text{max}\{0.3, 0.4\}/1=0.4/1$
2. $A \cap B: \mu_{A \cap B}(u) = \min\{\mu_A(u), \mu_B(u)\} = \mu_A(u) \wedge \mu_B(u)$
3. $\neg A: \mu_{\neg A}(u) = 1 - \mu_A(u)$

4.5.1.3. 模糊关系

1 笛卡尔乘积：了解即可

- A_i 是 U_i 上的模糊集
- $A_1 A_2 \dots A_n$ 的笛卡尔乘积：

$$A_1 \times A_2 \times \dots \times A_n = \int_{U_1 \times U_2 \times \dots \times U_n} (\mu_{A_1}(u_1) \wedge \mu_{A_2}(u_2) \wedge \dots \wedge \mu_{A_n}(u_n)) d(u_1, u_2, \dots, u_n)$$

- 笛卡尔乘积是 $U_1 \times U_2 \times \dots \times U_n$ 上的一个模糊集

2 n 元模糊关系：了解即可

- 基于 $U_1 \times U_2 \times \dots \times U_n$ 论域
- $R = \int \lim_{U_1 \times U_2 \times \dots \times U_n} \mu_R(u_1, u_2, \dots, u_n) / (u_1, u_2, \dots, u_n)$
- 二元模糊关系：基于 $U \times V$ ，当二者都为有限论域时，模糊关系可表示为举证

例如 $U=V=\{u_1, u_2, u_3\}$ 表示信任关系则有：

$$R = \begin{bmatrix} \mu_R(u_1, v_1) & \mu_R(u_1, v_2) & \dots & \mu_R(u_1, v_n) \\ \mu_R(u_2, v_1) & \mu_R(u_2, v_2) & \dots & \mu_R(u_2, v_n) \\ \vdots & \vdots & \ddots & \vdots \\ \mu_R(u_m, v_1) & \mu_R(u_m, v_2) & \dots & \mu_R(u_m, v_n) \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 0.3 & 0.8 \\ 0.9 & 1 & 0.6 \\ 0.7 & 0.5 & 1 \end{bmatrix}$$

== 3 模糊关系的合成(重点) ==

- R_1, R_2 分别是 $U \times V, V \times W$ 的模糊关系，其合成即为 $R_1 \circ R_2$
- $\mu_{R_1 \circ R_2}(u, w) = \bigvee_{v \in V} \{ \mu_{R_1}(u, v) \wedge \mu_{R_2}(v, w) \}$
- 示例：

$$R_1 = \begin{bmatrix} 0.4 & 0.5 & 0.1 \\ 0.2 & 0.6 & 0.2 \\ 1.5 & 0.3 & 0.2 \end{bmatrix} \quad R_2 = \begin{bmatrix} 0.2 & 0.8 \\ 0.4 & 0.6 \\ 0.6 & 0.4 \end{bmatrix}$$

$$(0,0): \begin{bmatrix} 0.4 & 0.5 & 0.1 \end{bmatrix} \begin{bmatrix} 0.2 \\ 0.4 \\ 0.6 \end{bmatrix} \rightarrow \max \left\{ \min\{0.4, 0.2\}, \min\{0.5, 0.4\}, \min\{0.1, 0.6\} \right\} = 0.4$$

$$\text{故 } R_1 \circ R_2(0,0) = 0.4$$

$$(0,1): \begin{bmatrix} 0.4 & 0.5 & 0.1 \end{bmatrix} \begin{bmatrix} 0.8 \\ 0.6 \\ 0.4 \end{bmatrix} \rightarrow \max \left\{ \min\{0.4, 0.8\}, \min\{0.5, 0.6\}, \min\{0.1, 0.4\} \right\} = 0.5$$

$$\text{故 } R_1 \circ R_2(0,1) = 0.5$$

$$\text{故 } R_1 \circ R_2 = \begin{bmatrix} 0.4 & 0.5 \\ 0.4 & 0.6 \\ 0.3 & 0.5 \end{bmatrix}$$

4.5.1.4. 模糊逻辑

- 含义：含有模糊概念、模糊数据的语句
- 形式： x_{is_A} ， A 是模糊概念(模糊集)；比如 张三 is 如存在的

4.5.1.5. 模糊匹配

- 形式： $IF (x_{is_A}) THEN (y_{is_B})$ ，证据和结论都用模糊命题表示， AB 是模糊概念
- 核心问题：条件的 A 与证据的 A' 不一定完全相同，例如

IF $x_{is_小}$ (知识) THEN $y_{is_大}$ (结论)
 $x_{is_微}$ (证据)

- == 匹配度：计算两个模糊概念(集)之间的相似程度：计算题重灾区 ==

1. 海明距离：

$$\begin{cases} d(A, B) = \frac{1}{n} \times \sum_{i=1}^n |\mu_A(u_i) - \mu_B(u_i)| \\ d(A, B) = \frac{1}{b-a} \int_a^b |\mu_A(u) - \mu_B(u)| du \end{cases}$$

2. 欧几里得距离：

$$d(A, B) = \sqrt{\frac{1}{n} \times \sum_{i=1}^n (\mu_A(u_i) - \mu_B(u_i))^2}$$

4 复合条件的模糊匹配

1. 条件： `E= x1_is_A1 AND x2_is_A2 AND...AND xn_is_An`

2. 证据： `x1_is_A1', x2_is_A2', ..., xn_is_An'`，匹配度 $\delta_{\text{match}}(A_i, A_i')$, $i=1, 2, \dots, n$

3. 整个条件与证据的匹配度

$$\delta_{\text{match}}(E, E') = \min\{\delta_{\text{match}}(A_i, A_i') \mid i=1, 2, \dots, n\}$$

$$\delta_{\text{match}}(E, E') = \prod_{i=1}^n \delta_{\text{match}}(A_i, A_i')$$

4.5.1.6. 模糊推理的基本模式

1 模糊假言推理

知识： IF `x_is_A` THEN `y_is_B`
证据： `x_is_A'`
结论： `y_is_B'`

2 模糊拒取式推理

知识： IF `x_is_A` THEN `y_is_B`
证据： `y_is_B'`
结论： `x_is_A'`

3 模糊推理方法(扎德)：由 `IF (x_is_A) THEN (y_is_B)` 求出 A 与 B 之间的模糊关系 R ，通过 R 与相应证据合成求出模糊结论

==4.5.2. 简单模糊推理==

4.5.2.1. 概述 IF (x_is_A) THEN (y_is_B)

1 什么是模糊推理：知识中只含简单条件，不带可信度因子

2 推理方法：

- 构造 A 与 B 间的模糊关系 R
- 如果已知证据 `x_is_A'` 且 A 与 A' 模糊匹配，则 $B' = A' \circ R$
- 如果已知证据 `x_is_B'` 且 B 与 B' 模糊匹配，则 $A' = R \circ B'$ ==记住这两个公式，Bar和Arab

4.5.2.2. 构造模糊关系 R 的方法==：必出一道计算题==

1 扎德方法：

1. 概述： $A \in \mathcal{F}(U), B \in \mathcal{F}(V)$ 表示为 $A = \int \mu_A(u) / u, \quad B = \int \mu_B(v) / v$

$$\begin{cases} \text{极大/小规则: } R_m = (A \times B) \cup (\neg A \times V) = \int_{U \times V} [\mu_A(u) \wedge \mu_B(v)] \vee [1 - \mu_A(u)] / (u, v) \\ \text{算术规则: } R_a = (\neg A \times V) \oplus (U \times B) = \int_{U \times V} 1 \wedge [1 - \mu_A(u) + \mu_B(v)] / (u, v) \end{cases}$$

==只要记住 $R_m = (A \times B) \cup (\neg A \times V)$ ==，其他仍和都不要了

2. 推理方法

- ==若已知证据 `x_is_A'` 则 $B' = A' \circ R_m$ 或 $B' = A' \circ R_a$ ==
- ==若已知证据 `y_is_B'` 则 $A' = R_m \circ B'$ 或 $A' = R_a \circ B'$ ==

3. 示例

题目与核心公式

$$\textcircled{1} U=V=\{1,2,3,4,5\} \rightarrow [0,1]$$

$$A=1/1+0.5/2, \quad B=0.4/3+0.6/4+1/5$$

$$\textcircled{2} \text{证据: } x \text{ is } A', \quad A'=1/1+0.4/2+0.2/3$$

$$\text{解: } R_m=(A \times B) \cup (\neg A \times V) \quad R_a=(\neg A \times V) \oplus (U \times B)$$

模糊集补集的求法

$$1. \text{计算 } \neg A.$$

$$A=1/1+0.5/2=1/1+0.5/2+0/3+0/4+0/5.$$

$$\text{要求 } \mu_A(x)+\mu_{\neg A}(x)=1, \quad x \in U=\{1,2,3,4,5\}$$

$$\Rightarrow \text{故 } \neg A=0/1+0.5/2+1/3+1/4+1/5$$

求笛卡尔乘积

$$2. \text{计算 } A \times B, \neg A \times V, U \times B.$$

$$\begin{cases} A=1/1+0.5/2+0/3+0/4+0/5 \\ B=0/1+0/2+0.4/3+0.6/4+1/5 \\ \neg A=0/1+0.5/2+1/3+1/4+1/5 \end{cases}$$

$$A \times B = \begin{bmatrix} 0 & 0 & 0.4 & 0.6 & 1 \\ 0 & 0 & 0.4 & 0.6 & 1 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{matrix} B \\ 1 \\ 0.5 \\ 0 \\ 0 \\ 0 \end{matrix}$$

$$\neg A \times V = \begin{bmatrix} 0 & 0.5 & 0.5 & 0.5 & 0.5 \\ 0 & 0.5 & 0.5 & 0.5 & 0.5 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix} \begin{matrix} V \rightarrow \text{结果全取1} \\ 0 \\ 0.5 \\ 1 \\ 1 \\ 1 \end{matrix}$$

$$U \times B = \begin{bmatrix} 0 & 0 & 0.4 & 0.6 & 1 \\ 0 & 0 & 0.4 & 0.6 & 1 \\ 0 & 0 & 0.4 & 0.6 & 1 \\ 0 & 0 & 0.4 & 0.6 & 1 \\ 0 & 0 & 0.4 & 0.6 & 1 \end{bmatrix} \begin{matrix} B \\ 1 \\ 0.5 \\ 1 \\ 1 \\ 1 \end{matrix}$$

每行取并集最小值

求笛卡尔并——(笛卡尔交就是取二者之一的较小者)

求笛卡尔有界和

合成模糊关系

$$\begin{cases} B_m' = A' \circ R_m \\ B_a' = A' \circ R_a \end{cases} \quad \begin{cases} A_m' = R_m \circ B' \\ A_a' = R_a \circ B' \end{cases}$$

$$A' = 1/1 + 0.4/2 + 0.2/3 + 0/4 + 0/5$$

$$B_m' = [1, 0.4, 0.2, 0, 0] \begin{bmatrix} 0 & 0 & 0.4 & 0.6 & 1 \\ 0.5 & 0.5 & 0.5 & 0.5 & 0.5 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix} = [0.4, 0.4, 0.4, 0.6, 1]$$

$$B_a' = [1, 0.4, 0.2, 0, 0] \begin{bmatrix} 0 & 0 & 0.4 & 0.6 & 1 \\ 0.5 & 0.5 & 0.5 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix} = [0.4, 0.4, 0.4, 0.6, 1]$$

$$A_m', A_a' \text{ 同理.}$$

2 Mamdani方法:

$R_c = A \times B = \lim_{U \times V} \mu_A(u) \wedge \mu_B(v) / (u,v)$ 则 $B_c' = A' \circ R_c$ 或者 $A_c' = R_c \circ B'$

3 Mizumoto方式: 一律不用看

1. R_s, R_g

$$\begin{cases} R_s = [A \times V \xrightarrow{s} U \times B] = \int_{U \times V} [\mu_A(u) \xrightarrow{s} \mu_B(v)](u, v) \\ \mu_A(u) \xrightarrow{s} \mu_B(v) = \begin{cases} 1, & \mu_A(u) \leq \mu_B(v) \\ 0, & \mu_A(u) > \mu_B(v) \end{cases} \end{cases}$$

$$\begin{cases} R_g = [A \times V \xrightarrow{g} U \times B] = \int_{U \times V} [\mu_A(u) \xrightarrow{g} \mu_B(v)](u, v) \\ \mu_A(u) \xrightarrow{g} \mu_B(v) = \begin{cases} 1, & \mu_A(u) \leq \mu_B(v) \\ \mu_B(v), & \mu_A(u) > \mu_B(v) \end{cases} \end{cases}$$

○ 若已知证据 x_is_A' 则 $B's = A' \circ R_s$ 或 $B'g = A' \circ R_g$

若已知证据 y_is_B' 则 $A's = R_s \circ B'$ 或 $A'g = R_g \circ B'$

○ 当 U, V 离散时:

$$R_{s \text{ or } g} = \begin{bmatrix} \mu_A(u_1) \xrightarrow{s \text{ or } g} \mu_B(v_1) & \cdots & \mu_A(u_1) \xrightarrow{s \text{ or } g} \mu_B(v_{\max}) \\ \vdots & \ddots & \vdots \\ \mu_A(u_{\max}) \xrightarrow{s \text{ or } g} \mu_B(v_1) & \cdots & \mu_A(u_{\max}) \xrightarrow{s \text{ or } g} \mu_B(v_{\max}) \end{bmatrix}$$

2. 其他关系的表示

$$\begin{cases} R_{sg} = [(A \times B) \xrightarrow{s} (U \times B)] \cap [(\neg A \times B) \xrightarrow{g} (U \times \neg B)] = \int_{U \times V} [\mu_A(u) \xrightarrow{s} \mu_B(v)] \wedge [(1 - \mu_A(u)) \xrightarrow{g} (1 - \mu_B(v))] / (\\ R_{gg} = [(A \times B) \xrightarrow{g} (U \times B)] \cap [(\neg A \times B) \xrightarrow{g} (U \times \neg B)] = \int_{U \times V} [\mu_A(u) \xrightarrow{g} \mu_B(v)] \wedge [(1 - \mu_A(u)) \xrightarrow{g} (1 - \mu_B(v))] / (\\ R_{gs} = [(A \times B) \xrightarrow{g} (U \times B)] \cap [(\neg A \times B) \xrightarrow{s} (U \times \neg B)] = \int_{U \times V} [\mu_A(u) \xrightarrow{g} \mu_B(v)] \wedge [(1 - \mu_A(u)) \xrightarrow{s} (1 - \mu_B(v))] / (\\ R_{ss} = [(A \times B) \xrightarrow{s} (U \times B)] \cap [(\neg A \times B) \xrightarrow{s} (U \times \neg B)] = \int_{U \times V} [\mu_A(u) \xrightarrow{s} \mu_B(v)] \wedge [(1 - \mu_A(u)) \xrightarrow{s} (1 - \mu_B(v))] / (\end{cases}$$

3. 示例

$$\begin{aligned} U &= V = \{1, 2, 3, 4, 5\} \\ A &= 1/1 + 0.5/2 + 0/3 + 0/4 + 0/5 \\ B &= 0/1 + 0/2 + 0.4/3 + 0.6/4 + 1/5 \\ \text{IF } x_is_A \text{ THEN } y_is_B \\ x_is_A' \\ A' &= 1/1 + 0.4/2 + 0.2/3 + 0/4 + 0/5 \end{aligned}$$

求解:

$$\begin{aligned} A &= [1, 0.5, 0, 0, 0] \text{ 在 } U \text{ 上} \\ B &= [0, 0, 0.4, 0.6, 1] \text{ 在 } V \text{ 上} \\ R_s &= \begin{bmatrix} \mu_A(1) \xrightarrow{s} \mu_B(1) & \cdots & \mu_A(1) \xrightarrow{s} \mu_B(5) \\ \vdots & & \vdots \\ \mu_A(5) \xrightarrow{s} \mu_B(1) & \cdots & \mu_A(5) \xrightarrow{s} \mu_B(5) \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix} \\ R_g &= \begin{bmatrix} \mu_A(1) \xrightarrow{g} \mu_B(1) & \cdots & \mu_A(1) \xrightarrow{g} \mu_B(5) \\ \vdots & & \vdots \\ \mu_A(5) \xrightarrow{g} \mu_B(1) & \cdots & \mu_A(5) \xrightarrow{g} \mu_B(5) \end{bmatrix} = \begin{bmatrix} \mu_B(1) & \mu_B(2) & \mu_B(3) & \mu_B(4) & 1 \\ \mu_B(1) & \mu_B(2) & \mu_B(3) & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0.4 & 0.6 & 1 \\ 0 & 0 & 0.4 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix} \end{aligned}$$

4.5.2.3. 各种模糊关系的性能分析

== 🚗 Pre: 这里这几个公式要记下来, 会出计算题==, 最好能有示例(见我的考点&例题总结)

$$\begin{cases} A = \int_U \mu_A(u)/u \\ \text{very } A = \int_U \mu_A^2(u)/u \\ \text{more/less } A = \int_U \mu_A^{0.5}(u)/u \end{cases} \begin{cases} \text{not } A = \int_U 1 - \mu_A(u)/u \\ \text{not very } A = \int_U 1 - \mu_A^2(u)/u \\ \text{not more/less } A = \int_U 1 - \mu_A^{0.5}(u)/u \end{cases}$$

后面的都不用看了

1 模糊假言推理

原则1

知识: IF x_is_A THEN y_is_B
证据: x_is_A
结论: y_is_B

原则2

知识: IF x_is_A THEN y_is_B
证据: $x_is_very_A$
结论: y_is_B or $very_B$

原则3

知识: IF x_is_A THEN y_is_B
证据: $x_is_more/less_A$
结论: y_is_B or $more/less_B$

原则4
知识: IF x_is_A THEN y_is_B
证据: x_is_not_A
结论: y_is_not_B or unknown

2 模糊拒取式推理

原则5
知识: IF x_is_A THEN y_is_B
证据: y_is_not_B
结论: x_is_not_A

原则6
知识: IF x_is_A THEN y_is_B
证据: y_is_not_very_B
结论: x_is_not_very_A

原则7
知识: IF x_is_A THEN y_is_B
证据: y_is_not_more/less_B
结论: x_is_not_more/less_B

原则4
知识: IF x_is_A THEN y_is_B
证据: y_is_B
结论: x_is_A or x_is_unknown

4.5.3. 模糊三段论推理:

==这里PPT对应一个例子看一下，因为是原题==

R1: IF x_is_A THEN y_is_B
R2: IF y_is_B THEN z_is_C

R3: IF x_is_A THEN z_is_C

- 1 ABC 的论域是 UVW , $R(A,B), R(B,C), R(A,C)$ 是由模糊知识得到的模糊关系
- 2 当满足 $R(A,B) \circ R(B,C) = R(A,C)$ 时，模糊三段论成立，模糊关系 R 满足三段论
- 3 满足关系:

$$\begin{cases} Y' = X'_1 \circ R(X_1, X_2) \circ R(X_2, X_3) \circ \dots \circ R(X_n, Y) \\ \text{在此处为: } \begin{cases} B' = A' \circ R(A, B) \\ C' = B' \circ R(B, C) = A' \circ R(A, B) \circ R(B, C) = A' \circ R(A, C) \end{cases} \end{cases}$$

4.5.4. 多维模糊理论

知识: IF x1_is_A1 AND x2_is_A2 AND ... AND xn_is_An THEN y_is_B
证据: x1_is_A1' x2_is_A2' ... xn_is_An'

结论: y_is_B'

$A_i, A_i' \in \mathcal{F}(U_i), B, B' \in \mathcal{F}(V), i=1, 2, \dots, n$

- 1 扎德方法: 前提是 A_i 在相同的论域==, 这个要记下来==
 1. 求出所有 $A_i, i=1, 2, \dots, n$ 和 $A_i', i=1, 2, \dots, n$ 的交集(最小值)为 A 和 A'
 2. 求出 A, B 之间的模糊关系为 $R(A, B)$
 3. 由 $B' = A \circ R(A, B)$, 示例如下
- 2 つかもと方法, ==这个也要记下来==
 1. 先求出每个 $R(A_i, B), i=1, 2, \dots, n$
 2. 求出 $B_i' = A_i \circ R(A_i, B), i=1, 2, \dots, n$
 3. 最后 $B' = B_1' \cap B_2' \cap \dots \cap B_n'$

4.5.5. 其他模糊推理

- 1 多重模糊推理: ==这个需要了解==

```

IF x_is_A1 THEN y_is_B1 ELSE
IF x_is_A2 THEN y_is_B2 ELSE
.....
IF x_is_An THEN y_is_Bn

```

简单情况

```

知识: IF x_is_A THEN y_is_B ELSE y_is_C
证据:   x_is_A'
结论:                                     y_is_D

```

$A \in \mathcal{F}(U), B, C, D \in \mathcal{F}(V)$

知识: IF x is A THEN y is B ELSE y is C
 证据: x is A'

结论: y is D

其中 $A, A' \in \mathcal{F}(U); B, C, D \in \mathcal{F}(V)$ 。

推理方法: 通过A、B、C构造 $U \times V$ 上的一个模糊关系R,
 然后, 通过A'与R的合成得到结论D, 即

$$D = A' \circ R$$

以下公式(多重模糊推理中的模糊关系)不用记, 考到了会直接给你, PPT中往下复杂的公式都同理

$$\begin{aligned}
 R_m &= (A \times B) \cup (\neg A \times C) \\
 &= \int_{U \times V} [\mu_A(u) \wedge \mu_B(v)] \vee [(1 - \mu_A(u)) \wedge \mu_C(v)] / (u, v) \\
 R_a &= (\neg A \times V \oplus U \times B) \cap (A \times V \oplus U \times C) \\
 &= \int_{U \times V} 1 \wedge [1 - \mu_A(u) + \mu_B(v)] \wedge [\mu_A(u) + \mu_C(v)] / (u, v)
 \end{aligned}$$

2 带可信度因子的模糊推理

```

知识: IF x_is_A THEN y_is_B   CF1
证据:   x_is_A'               CF2
结论:                                     y_is_B'   CF

```

可信度计算:

$$CF = \begin{cases} \delta_{\text{match}}(A, A') \times CF_1 \times CF_2, & \text{for the first case,} \\ \delta_{\text{match}}(A, A') \times \min\{CF_1, CF_2\}, & \text{for the second case,} \\ \delta_{\text{match}}(A, A') \times \max\{0, CF_1 + CF_2 - 1\}, & \text{for the third case,} \\ \min\{\delta_{\text{match}}(A, A'), CF_1, CF_2\}, & \text{for the fourth case.} \end{cases}$$

5. 搜索策略:

5.1. 基本概念

5.1.1. 什么是搜索

1 定义: 在知识库中找到可利用的知识, 构造一条代价较小的推理路线, 从而解决问题

2 分类

1. 盲目搜索: 按预设控制策略搜索,
2. 启发式搜索: 搜索过程加入与问题有关的启发信息

问题求解过程可看作是搜索过程

5.1.2. 问题及其求解过程的表示: 状态空间法

1 状态: 描述问题求解过程中不同时刻的状态, 是一个向量 $S_k = (S\{k_0\}, S\{k_1\}, \dots)$

2 算符: 使问题从一个状态转为另一个状态的操作, 比如产生是系统的产生式规则

3 状态空间: 所有可能的状态+一切可用算符


4 求解过程:

1. 过程: 表示出所有状态, 定义一组算符→不断把算符作用给状态→得到目标状态
2. 解: 从初始状态→目标状态, 所采用的算符序列。算符最少的话就是最优解

5.1.3. AND/OR树表示法：==这个不用看==

1 复杂问题的处理


1. 分解：把复杂问题分解为若干子问题，子问题再继续分解，形成与或数
2. 等价变换：把原问题化为若干容易求解的新问题吗，形成与或数



2 基本概念

1. 本源问题：不能再分解的，可以直接解的子问题
2. 端节点：没有子节点的结点
3. 终止结点：本源问题对应的结点
4. 可解结点：是终止结点or是或结点且子节点中至少一个可解or是与结点且子节点全部可解
5. 解树：可解节点构成的子树，是表示问题解决路径的树形结构

5.2. 状态空间的搜索策略



5.2.1. 状态空间搜索概述

1 有关数据结构：

OPEN表		CLOSE表		
状态节点	父节点	编号	状态节点	父节点

1. OPEN表：存放刚生成的结点，不同策略下结点的排列顺序不同
 2. CLOSE表：结点扩展前要将其放入CLOSE表
- PS. 结点扩展：用算符作用于节点，生成一系列结点



2 搜索过程：给定初始/最终结点，找到最佳路径，==详见A*算法==

5.2.2. 广度优先搜索

1 概述

1. 基本思想：初始节点开始，逐层扩展并考察(是否为目标节点)结点，一层结点全扩展考察完，再扩展下一层的结点
2. OPEN表中的结点按照进入顺序排列
3. 特点是：盲目性大，但一定能得到最短解(反之深度优先不一定得到的是最短解)

2 广度优先搜索过程：注意以下将其子节点放入OPEN表尾部，尾部改为首部就是深度优先了




OPEN		CLOSE
R0 \	1	\
R1 OP1 \		1
R1 OP2 \ 2 3 4 5	←	1
R2 OP1 \ \ 3 4 5		1 2
R2 OP2 \ \ 3 4 5 6 7	←	1 2
R3 OP1 \ \ \ 4 5 6 7		1 2 3
R3 OP2 \ \ \ 4 5 6 7 8 9	←	1 2 3
R4 OP1 \ \ \ \ 5 6 7 8 9		1 2 3 4
R4 OP2 \ \ \ \ 5 6 7 8 9 10 11	←	1 2 3 4
R5 OP1 \ \ \ \ \ 6 7 8 9 10 11		1 2 3 4 5
R5 OP2 \ \ \ \ \ 6 7 8 9 10 11 12 13	←	1 2 3 4 5
R6 OP1 \ \ \ \ \ \ 7 8 9 10 11 12 13		1 2 3 4 5 6
R6 OP2 \ \ \ \ \ \ 7 8 9 10 11 12 13 14	←	1 2 3 4 5 6
R7 OP1 \ \ \ \ \ \ \ 8 9 10 11 12 13 14		1 2 3 4 5 6 7
R7 OP2 \ \ \ \ \ \ \ 8 9 10 11 12 13 14 15	←	1 2 3 4 5 6 7
R8 OP1 \ \ \ \ \ \ \ \ 9 10 11 12 13 14 15		1 2 3 4 5 6 7 8
R8 OP2 \ \ \ \ \ \ \ \ 9 10 11 12 13 14 15 16	←	1 2 3 4 5 6 7 8
R9 OP1 \ \ \ \ \ \ \ \ \ 10 11 12 13 14 15 16		1 2 3 4 5 6 7 8 9
R9 OP2 \ \ \ \ \ \ \ \ \ 10 11 12 13 14 15 16 17	←	1 2 3 4 5 6 7 8 9
R10 OP1 \ \ \ \ \ \ \ \ \ \ 11 12 13 14 15 16 17		1 2 3 4 5 6 7 8 9 10
R10 OP2 \ \ \ \ \ \ \ \ \ \ 11 12 13 14 15 16 17 18	←	1 2 3 4 5 6 7 8 9 10
R11 OP1 \ \ \ \ \ \ \ \ \ \ \ 12 13 14 15 16 17 18		1 2 3 4 5 6 7 8 9 10 11
R11 OP2 \ \ \ \ \ \ \ \ \ \ \ 12 13 14 15 16 17 18 19	←	1 2 3 4 5 6 7 8 9 10 11
R12 OP1 \ \ \ \ \ \ \ \ \ \ \ \ 13 14 15 16 17 18 19		1 2 3 4 5 6 7 8 9 10 11 12
R12 OP2 \ \ \ \ \ \ \ \ \ \ \ \ 13 14 15 16 17 18 19 20	←	1 2 3 4 5 6 7 8 9 10 11 12
R13 OP1 \ \ \ \ \ \ \ \ \ \ \ \ \ 14 15 16 17 18 19 20		1 2 3 4 5 6 7 8 9 10 11 12 13
R13 OP2 \ \ \ \ \ \ \ \ \ \ \ \ \ 14 15 16 17 18 19 20 21	←	1 2 3 4 5 6 7 8 9 10 11 12 13
R14 OP1 \ \ \ \ \ \ \ \ \ \ \ \ \ \ 15 16 17 18 19 20 21		1 2 3 4 5 6 7 8 9 10 11 12 13 14
R14 OP2 \ \ \ \ \ \ \ \ \ \ \ \ \ \ 15 16 17 18 19 20 21 22 23	←	1 2 3 4 5 6 7 8 9 10 11 12 13 14
R15 OP1 \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ 16 17 18 19 20 21 22 23		1 2 3 4 5 6 7 8 9 10 11 12 13 14 15
R15 OP2 \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ 16 17 18 19 20 21 22 23 24 25	←	1 2 3 4 5 6 7 8 9 10 11 12 13 14 15
R16 OP1 \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ 17 18 19 20 21 22 23 24 25		1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16
R16 OP2 \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ 17 18 19 20 21 22 23 24 25 26	←	1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16
R17 OP1 - \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ \ 18 19 20 21 22 23 24 25 26		1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17

n为目标结点

5.2.3. 有解深度优先算法==(了解深度优先就行了，这个不用看)==

1 基本思想：深度优先搜索的时候设置界限\$d_m\$, 搜索达到深度界限后，不管找没找到都换个分支

2 流程：



3 特点：由于深度限制不一定能找到解，所以深度设置也困难，找到的也不一定是最优的

4 改进1：先设置一较小 d_m ，当到达了 d_m 深度还未找到，就加深深度

5 改进2：增加一个表 R

1. 每找到一个目标节点就，把他放进 R 并且设置 d_m 为其路径长
2. 然后以 d_m 有限度的深度优先搜索
3. 不断找到目标节点不断更新 d_m ，最后一定得到最优解

5.2.4. 代价树的广度/深度优先搜索

==(广度优先看，深度优先不看)==


1 基本概念

1. 代价树：边上标有代价的树
2. 代价： $g(x)$ 是初始结点 S_0 到结点 x 的代价， $c(x_1, x_2)=g(x_2)-g(x_1)$ 是两结点之间的代价

2 基本思想：OPEN表中的节点按代价从小到大排序，每次取出代价最小的结点

3 特点：代价树的广度优先一定可以求得最优解

4 过程



5.2.5. 启发式搜索，==一定要看==

- 1 启发性信息：指导搜索，与问题有关的信息
- 2 估价函数：评估结点重要性， $f(x)=g(x)+h(x)$


	$g(x)$	$h(x)$ 启发函数
含义	初始节点→x的代价	x→目标结点，最优路径的预估代价
特点	有利于完备性，不利于效率	不利于完备性，有利于效率

+ 重拍九宫中， $h(x)$ 是 x 的格局与目标节点格局不相同的牌数

- 3 局部择优搜索==(不看)==：一个结点扩展后，按 $f(x)$ 对子节点计算估计价值，选择价值最小的下一个考察

深度优先+代价树深度优先，均为局部择优搜索的特例

- 4 全局择优搜索：一个结点扩展后，从OPEN表全体中，选一个估价最小的结点下一个考察




5.2.6. A*算法：这一部分全部PPT都要看

1 算法思想：基于一般搜索过程，加上以下限制(S_0 是初始节点)

1. OPEN表中节点按估价函数 $f(x)=g(x)+h(x)$ 小至大排序
2. $g(x)$ 是 S_0 到 x 路径的代价， $g^*(x)$ 是 S_0 到 x 最小代价， $g(x)$ 可估计 $g^*(x)$
3. $h^*(x)$ 是 x 到目标节点最小代价， $h(x)$ 是 $h^*(x)$ 下界

2 算法流程：气泡中为 A^* 算法相较于一般搜索过程的具象，==这个一定会出大题==



3 A^* 算法的性质：


1. 可纳性==(这个不用看)==: A^* 算法可纳
 - 可解状态空间图: 初始→目标节点有路径存在
 - 可纳性: 搜索算法可在有限步终止, 并找到最优秀解
2. 最优性: $h(x)$ 越大启发信息就越多, 搜索效率越高
3. 单调性==(这个很重要)==: 要求启发函数 $h(x)$ 单调搜索代价会更低
 单调的条件: $h(s_g)=0$, $h(x_i) \leq h(x_j) + c(x_i, x_j)$

6. 机器学习==(重点看6.2, 6.1扫一遍吧)==

6.1. 概述

6.1.1. 什么是ML

- 1 机器学习定义: 机器模拟人类学习
- 2 每次释义: KDD知识发现, DM数据挖掘, ML机器学习
- 3 机器学习系统基本结构



- 4 学习环节的一般过程: 确定模型→收集数据→清洗数据→提取特征→训练→获得知识

6.1.2. ML分类

- 1 有无指导: 有监督, 无监督, 强化学习
- 2 学习方法: 类比, 返利, 解释学习
- 3 推理策略: 演绎, 归纳, 类比学习

6.1.3. ML基本问题

ML: 在现有观察基础上求得学习函数 $L:S(\text{数据空间}) \rightarrow Z(\text{目标空间})$

问题类型	分类	预测	聚类	联想	优化
L	分类器	回归曲线(面)	聚类函数	自身映射	$S \rightarrow \text{Max}\{d[F(S)]\}$
Z	已知离散值	连续值	未知离散值	$Z=S$	数据空间的函数 $F(S)$, 其度量为 $d[F(S)]$
训练数据	$\langle D, C \rangle, D \subseteq S$	$\langle D, R \rangle, D \subseteq S$	$D, D \subseteq S$	$D, D \subseteq S$	$D, D \subseteq S$
图示			同分类的		
特点	监督学习(目标已知)	已知模型类别求参数	无监督学习	\	\
目的	分为已知类	预测	分为未知类	发现不同数据间的依赖关系	寻找使 $d[F(S)]$ 到达极值的方法
方法	SVM, Bayes, 决策树	神经网络, 回归	各种聚类方法	反馈神经网络	遗传算法


6.1.4. 学习成果的评估

- 1 评估原则: 模型泛化能力, 算法复杂度
 1. 鲁棒性: 健壮性, 系统处理非正常数据的能力
 2. 适应性: 对不同数据, 模型本身需要做多少人工调整
 3. 简洁性, 可解释性: 有限选择更简单的假设
- 2 测试集:
 1. 保留法: 从数据集中, 抽取部分为测试集, 剩下为训练集
 2. 交叉验证: 数据集划分为k个不相交的子集, 选一个作测试, 其他做训练
 3. 随机法: 随机抽一部分数据做训练集, 好处是可以无限重复
- 3 学习有效性指标

指标	公式	解释
误差	$\text{Error}(T) = \sum \limits_{i=1}^T$	T
正确率	$\text{Accuracy}(T) = \frac{1}{T} \sum \limits_{i=1}^T$	$\frac{1}{T} \times \text{Error}(T) < \epsilon$

指标	公式	解释
复合指标	$\text{precision}(T) = \frac{a}{a+b}$	a
F_{β} 度量	$F_{\beta}(T) = \frac{(1 + \beta^2) \text{precision}(T) \text{recall}(T)}{\beta^2 \text{precision}(T) + \text{recall}(T)}$	精度和召回率的调和平均数， β 为精度较召回率权重
宏平均法	$\text{precision}(\text{macro})(T) = \frac{1}{k} \sum_{i=1}^k \text{precision}_i(T)$, $\text{recall}(\text{macro})(T) = \frac{1}{k} \sum_{i=1}^k \text{recall}_i(T)$	将测试集分为k个目标类别，计算每类精度和召回率，再求平均
微平均法	$\text{precision}(\text{micro})(T) = \frac{\sum_{i=1}^k a_i}{\sum_{i=1}^k (a_i + b_i)}$	a_i

+ 复合指标的参数含义




6.2. 决策树学习

6.2.1. 决策树的表示

水果分类
特征向量: {颜色, 尺寸, 形状, 味道}
四种属性: 颜色(红绿蓝), 尺寸(大中小), 味道(酸甜), 形状(圆细)
样本集合: 一批水果, 直到其特征向量+类别
问题: 一个新水果, 观测得其特征向量, 如何为其分类?

==关注这个图==




1 结构: 把实例从根排列到叶子来分类

1. 叶结点: 实例所属分类
2. 结点: 实例对应的一个属性

2 实例分类流程: 测试根节点属性→按实例属性向下移动→在新结点重复以上过程

6.2.2. ID3算法



6.2.2.1. 算法思想：自顶向下贪婪遍历可能的决策树空间

1 核心：如何选取每个结点测试的属性

2 主要步骤

- 根结点放什么属性：根据每个实例属性单独分类训练样例的能力，选分类能力最好的属性为根
- 根属性的每个可能值产生一个分支，顺着分支把样例分配过去
- 重复以上过程

6.2.2.2. 信息增益：==重点关注==

度量属性区分训练样例的能力

1 样本 D 的熵： $\text{Entropy}(D) = -\sum_{i=1}^c P_i \log_2(P_i)$

- 样本来自 c 个不同类别
- P_i 为 i 类样本所占比例
- 熵越小样本越纯净

2 信息增益： $\text{Gain}(D, A) = \text{Entropy}(D) - \sum_{v \in \text{Values}(A)} \frac{|D_v|}{|D|} \text{Entropy}(D_v)$


- $\text{Gain}(D, A)$ ：应用属性 A 于数据集 D ，导致的 D 期望熵的减少程度
- $\text{Values}(A)$ ：属性 A 所有可能取值的集合
- $D_v = \{d \in D, d \text{ 的属性 } A \text{ 的值为 } v\}$

6.2.2.3. 决策树结点划分的三种情况

- 1 结点的样本同属一类：绝对纯净，不可再分
- 2 结点样本不属同一类
 1. 不可再分情形：划分后，子节点不可能具有更低的平均熵
 2. 可再分情形：划分后，子节点具有更低的平均熵

6.2.2.4. 确定叶节点&过学习欠学习：==重点关注，尤其是阈值方法==

- 1 是否要极致追求叶节点纯净度？(把所有可划分的结点全部划分到底，成为不可划分子节点)
 1. 划分到底：会过学习(过拟合)
 2. 不分到底：可能会欠学习
- 2 平衡过学习/欠学习：测试集方法



- 3 阈值方法：
 1. 决策树训练前，设定阈值作为终止学习条件(信息增益<阈值，结点样本量/全体样本比例<阈值)
 2. 学习过程中一个结点满足条件，就终止学习
- 4 叶节点分类：叶结点的样本中， i 类样本最多，就称之为 i 类叶节点

6.2.2.5. 决策树的规则后修剪：重点关注四个步骤

- 1 先允许过度拟合
- 2 从根到叶的路径就是一条规则，把得到的决策树转化为规则集合
- 3 对每条规则，若删除这个规则的一个前件不会降低规则的分类精度，就删除此前件
- 4 按修建后规则的精度对所有规则排序，按照此顺序来对规则分类

6.2.2.6. 过拟合问题

- 1 假设空间 H 训练集 D (太长是因为训练集选太小了)
 - 2 对假设 $h \in H$ ， $\exists h' \in H$ 使得
 1. 训练集 D 上 h 错误率更小
 2. 全体可能数据上 h' 错误率更小
 - 3 那么假设 h 就过拟合了训练集 D
- + 信息增益度量问题：信息增益度量会偏向于有较多可能值的属性

7. 神经网络：


==和决策树一样，关注一下过学习/欠学习的知识==

关注网络的设计，几个输入单元几个输出端元，隐藏层多少个神经元等等==(简答题)==

7.1. 神经网络单元形态

7.1.1. MP模型



1 结构



符号	名称	值
w_{ij}	连接权(i, j 两神经元的连接强度)	可调整
u_i	i 神经元的活跃值(状态)	$u_i = \sum_{k=1}^n w_{ki} x_k - \theta_i$
y_i	i 神经元的输出	$y_i = f(u_i)$
θ_i	i 神经元的阈值	可调整

2 神经元的输出函数 $f(u_i)$

1. 采用阶跃函数: $f(u_i) = 1, (u_i > 0)$
2. 采用非线性函数: 特点是真负无穷都可饱和



7.1.2. PDP(并行分布处理)模型

1 PDP单元的结构


1. 输入: 把所有输入加权求和就是其输入
2. 激活状态: 当前状态+输入→激活值
3. 每个单元都有输出

2 单元之间: PDP有很多单元, 按照一定模式连接, 系统通过经验修改连接强度学习规则


3 原理: 通过连接强度的变化来产生学习

7.2. 神经网络拓扑形态


1 前馈网络: 每层直接收上一层输入, 如BP



2 反馈网络: 从输出层到输入层有反馈, 如Hopfield



3 竞争网络：同一层的神经元之间也互相连接，如ART/SOM



4 全连接网络：疯子

7.3. 神经网络的学习

1 学习概念：改变神经网络内部表示，使得输入输出向好的方向发展

2 学习分类：


1. 按如何改变网络结构：改变权值，改变拓扑，二者兼具
2. 按确定性：确定性学习/不确定性学习

3 学习规则

1. Hebb：两个神经元同时处于兴奋状态，则二者连接权值加强
2. Δ ：根据期望值和实际值差值，来调整权值，核心在于调整 Δ
3. W-H：根据期望值和实际值均方差，来调整权值
4. 竞争学习：一层中输出最大的为胜者神经元，只调整胜者神经元有关权值

7.4. BP算法

7.4.1. 结构



1 输入：所有输入信号和， $\text{net}_j = \sum_{i=1}^n w_{ij}x_i = \sum_{i=1}^n w_{ij}y_i$

2 输出：可以是 $y_j = f(\text{net}_j) = \frac{1}{1 + e^{-\text{net}_j}}$ ，也可以是 tanh ，必须是处处可微分的

2 拓扑结构：由输入维度，隐藏层数量，输出维度决定

7.4.2. 算法过程

- 1 初始化：设置权值为小随机数
- 2 向前传播：输入一个样本 X_p ，输出 Y_p
- 3 向后传播：
 - 1. 算出与预期的误差 $E_p = \frac{1}{2} \sum \limits_{i=1}^m (y_i - o_i)^2$
 - 2. 按极小化误差的方式调整权矩阵
注意这样会导致后出现的样本更影响结果，solution是样本输入完后才累计调整一次
 - 3. 累计误差 $E = E + E_p$ 最后 E 就是整个样本集误差
- 4 重复2-3步，直到误差足够小

7.4.3. 权值调整：使权值沿误差函数的负梯度方向改变

- 1 上一层第 i 个神经元 $\rightarrow$ （连接） $\rightarrow$ 输出层第 j 个神经元

$\Delta w_{ij} = \eta \cdot \delta_j \cdot o_i$ 其中 $\delta_j = (t_j - o_j) \cdot f'(net_j)$

参数	含义
Δw_{ij}	第 i 个神经元到第 j 个神经元的权值变化
η	学习率，决定权值调整的步长
δ_j	输出层第 j 个神经元的误差项
t_j	输出层第 j 个神经元的目标输出
o_j	输出层第 j 个神经元的实际输出
$f'(net_j)$	输出层第 j 个神经元激活函数的导数
o_i	上一层（隐藏层）第 i 个神经元的输出


- 2 $k-1$ 层第 i 个神经元 $\rightarrow$ （连接） $\rightarrow$ k 层第 j 个神经元：

$\Delta w_{ij}^{(k)} = \eta \cdot \delta_j^{(k)} \cdot o_i^{(k-1)}$ 其中 $\delta_j^{(k)} = \left(\sum \delta_m^{(k+1)} w_{jm}^{(k+1)} \right) \cdot f'(net_j^{(k)})$

参数	含义
$\Delta w_{ij}^{(k)}$	$k-1$ 层第 i 个神经元到 k 层第 j 个神经元的权值变化
$\delta_j^{(k)}$	k 层第 j 个神经元的误差项
$\sum \delta_m^{(k+1)} w_{jm}^{(k+1)}$	$k+1$ 层的误差项与权值的加权和，表示 k 层第 j 个神经元对后续层误差的贡献
$f'(net_j^{(k)})$	k 层第 j 个神经元激活函数的导数
$o_i^{(k-1)}$	$k-1$ 层第 i 个神经元的输出

7.4.4. BP算法注意事项

- 1 激活函数：满足非线性/有界/连续/可微
- 2 目标向量的选择：向量的每个分量，不超过激活函数的值域
- 3 权系数的初始化：随机化均匀赋值
- 4 学习速率 η ：一般取0.1，过大会导致不收敛。过小会收敛慢
- 5 误差函数局部极小值：当训练过程被困在局部极小值时，需要对权值重新初始化，然后重新训练
- 6 学习曲线：



1. 样本划分: 训练集(调整权值), 确认集(确定最佳权值), 测试集(评估实际性能)
2. Epoch: 所有样本都参与了一次对权值的更新, 就算一次Epoch
- 7 过拟合: 对训练集分类能力强, 对测试集却很差, solution是在确认集平均误差函数最小时终止
- 8 隐藏层数目: 过多容易过拟合, 一般取样本数/10

PS. 补充内容


PS.1. 模式识别

PS.1.1. 什么是模式识别(eg.计算机认字)

- 1 含义: 对观察到的物理对象识别分类
- 2 模式: 存储于计算机内的有关物理对象的观测信息
- 3 如何让机器模式识别: 采集数据+模式识别算法
- 4 模式识别的意义: 对外界感知和识别是智能的基础

PS.1.2. 模式识别系统设计: 鱼类分类为例

- 1 获取观测量: 比如获得+分割图像, 得到单个鱼的图像
- 2 特征提取:
 1. 如鱼的长短, 暗亮等得到**特征向量**
 2. 特征向量所有可能取值得到特征空间
 3. 样本 $\langle x, y \rangle$ 中 x 表示特征向量 y 表示样本类别, 如 $y = -1/1$ 表示A类/B类鱼
- 3 分类器训练: 根据样本集, 构造一个判定函数 $d(x)$ 来实现分类
 1. 设计函数是要求A/B类鱼样本有, $d(x) < 0/d(x) > 0$, $d\{归一化\}(x) = -1/d\{归一化\}(x) = 1$
 2. $\{x | d(x) = 0\}$ 为分类面
 3. 本例中采用线性模型, 则如下图, 这里分类器复杂度极低(出现欠学习, 泛化性低)



- 4 分类器测试: 用新样本测试分类器性能, 看能不能正确分类得到误差, 随后进行优化
- 5 分类器设计的考虑因素:
 1. 两类鱼特征向量的真实分布
 2. 训练集测试集越多越好
 3. 分类器不能太复杂, 不然会过拟合导致泛化程度降低(如下图), 复杂度应该适中且遵从以下原则
 - Occam razor原则: 误差相近选择复杂度低的分类器
 - 用学习曲线方法选择

